



**UNITINS**  
UNIVERSIDADE ESTADUAL DO TOCANTINS

**TOCANTINS**  
GOVERNO DO ESTADO



UNIVERSIDADE ESTADUAL DO TOCANTINS  
CÂMPUS DE PALMAS  
CURSO DE SISTEMAS DE INFORMAÇÃO

**ANÁLISE E CLASSIFICAÇÃO DE IMAGENS DE MUDAS DE  
PLANTAS VIA MLP E CNN**

AUGUSTO PUGAS NASCIMENTO AIRES

Palmas - TO

2023



**UNITINS**  
UNIVERSIDADE ESTADUAL DO TOCANTINS

**TOCANTINS**  
GOVERNO DO ESTADO



UNIVERSIDADE ESTADUAL DO TOCANTINS  
CÂMPUS DE PALMAS  
CURSO DE SISTEMAS DE INFORMAÇÃO

**ANÁLISE E CLASSIFICAÇÃO DE IMAGENS DE MUDAS DE  
PLANTAS VIA MLP E CNN**

AUGUSTO PUGAS NASCIMENTO AIRES

Trabalho de Conclusão de Curso apresentado ao  
Curso de Sistemas de Informação da Universidade  
Estadual do Tocantins - UNITINS como parte dos  
requisitos para a obtenção do grau de Bacharel em  
Sistemas de Informação.

Palmas - TO

2023



**TOCANTINS**  
GOVERNO DO ESTADO



**AUGUSTO PUGAS NASCIMENTO AIRES**  
**ANÁLISE E CLASSIFICAÇÃO DE IMAGENS DE MUDAS DE**  
**PLANTAS VIA MLP E CNN**

Trabalho de conclusão de curso  
apresentado ao curso de Sistemas de  
Informação, como exigência para  
obtenção do grau de Bacharel.

Aprovado pela Banca Examinadora em 24 de junho de 2023.

Marco Antônio Firmino de Sousa  
Prof. Orientador

Antônio Rafael de  
Souza Alves Bosso  
Prof. Membro da Banca

Douglas Chagas da Silva  
Prof. Membro da Banca

**Campus Palmas, Bloco B, 24 de junho de 2023**

**Dados Internacionais de Catalogação na Publicação  
(CIP) Sistema de Bibliotecas da Universidade Estadual  
do Tocantins**

---

A298a                      AIRES, Augusto Pugas Nascimento  
                                 Análise e classificação de imagens de mudas de  
                                 plantas via MLP e CNN. Augusto Pugas Nascimento  
                                 Aires. - Palmas, TO, 2023  
  
                                 Monografia Graduação - Universidade Estadual do  
                                 Tocantins – Câmpus Universitário de Palmas - Curso de  
                                 Sistemas de Informação, 2023.  
  
                                 Orientador: Marco Antonio Firmino de Sousa  
  
                                 1. Deep Learning. 2. Classificação de imagens. 3.  
                                 Classificação de imagens de mudas de plantas.

**CDD 610.7**

---

TODOS OS DIREITOS RESERVADOS – A reprodução total ou parcial, de qualquer forma ou por qualquer meio deste documento é autorizado desde que citada a fonte. A violação dos direitos do autor (Lei nº 9.610/98) é crime estabelecido pelo artigo 184 do Código Penal.

Elaborado pelo sistema de geração automática de ficha catalográfica da UNITINS com os dados fornecidos pelo(a) autor(a).

## **ATA DE DEFESA DE TRABALHO DE CONCLUSÃO DE CURSO DO CURSO DE SISTEMAS DE INFORMAÇÃO DA FUNDAÇÃO UNIVERSIDADE ESTADUAL DO TOCANTINS - UNITINS**

Aos **24** dias do mês de **Junho** de **2023**, reuniu-se na Fundação Universidade Estadual do Tocantins, Câmpus Palmas, Bloco B, às **10:00 horas**, sob a Coordenação do Professor **Marco Antônio Firmino de Sousa** a banca examinadora de Trabalho de Conclusão de Curso em Sistemas de Informação, composta pelos examinadores Professor **Marco Antônio Firmino de Sousa** (Orientador), Professor **Douglas Chagas da Silva** e Professor **Antônio Rafael de Souza Alves Bosso**, para avaliação da defesa do trabalho intitulado “**Análise e Classificação de Imagens de Mudas de Plantas via MLP e CNN**” do acadêmico **Augusto Pugas Nascimento Aires** como requisito para aprovação na disciplina Trabalho de Conclusão de Curso II (TCC II). Após exposição do trabalho realizado pelo acadêmico e arguição pelos Examinadores da banca, em conformidade com o disposto no Regulamento de Trabalho de Conclusão de Curso em Sistemas de Informação, a banca atribuiu a pontuação: 9,5.

Sendo, portanto, o Acadêmico: ( X ) Aprovado ( ) Reprovado

Assinam esta Ata:

Professor Orientador: \_\_\_\_\_

Examinador: \_\_\_\_\_

Examinador: \_\_\_\_\_

**Marco Antônio Firmino de Sousa**  
**Presidente da Banca Examinadora**



*Este trabalho é dedicado à minha família, pelo apoio incondicional.*

# Agradecimentos

Aos meus pais e irmãos que sempre me incentivaram a superar as dificuldades. Aos meus amigos de jornada, por não me deixarem desistir.

*“Cada hora de tempo perdida  
na mocidade é uma possibilidade  
a menos nos sucessos do futuro.”  
(Napoleão Bonaparte)*



# Resumo

**Resumo:** A agricultura brasileira está em busca constante de otimização de suas práticas, utilizando inteligência artificial e análise de imagens para detectar e classificar plantas, impulsionando a eficiência e sustentabilidade do setor. Nesse sentido, um estudo de caso exploratório foi realizado para comparar modelos de aprendizado de máquina na classificação de mudas de plantas, buscando identificar o modelo mais eficiente em termos de recursos e precisão. Os resultados obtidos ressaltaram a eficácia do *Deep Learning* na classificação de imagens, demonstrando seu potencial em diversas aplicações. A constante melhoria e aperfeiçoamento dos modelos desempenham um papel fundamental no avanço dessa área, especialmente para solucionar desafios complexos relacionados à identificação e classificação de imagens. Ambas as técnicas de classificação mostraram-se capazes de classificar as imagens, entretanto, a MLP obteve resultados significativos apenas para duas classes, enquanto a CNN demonstrou bom desempenho em ambos os experimentos.

**Palavras-chaves:** Classificação; AI; CNN; MLP; Plantas.

# Abstract

**Abstract:** Brazilian agriculture is constantly seeking to optimize its practices, using artificial intelligence and image analysis to detect and classify plants, boosting the sector's efficiency and sustainability. In this sense, a study of exploratory case was carried out to compare machine learning models in classification of plant seedlings, seeking to identify the most efficient model in terms of features and accuracy. The results obtained highlighted the effectiveness of Deep Learning in image classification, demonstrating its potential in several applications. the constant improvement and refinement of models play a key role in advancing this area, especially to solve complex challenges related to the identification and image classification. Both classification techniques were able to classify the images, however, the MLP obtained significant results only for two classes, while CNN performed well in both experiments.

**Key-words:** Classification; AI; CNN; MLP; Plants.

# Lista de ilustrações

Figura 1 – Fluxograma do Trabalho . . . . .	22
Figura 2 – Mosaico com exemplos de imagens de mudas plantas . . . . .	24
Figura 3 – Imagem Redimensionada. . . . .	26
Figura 4 – Diagrama do modelo CNN . . . . .	27
Figura 5 – Resultado do Experimento 1 . . . . .	27
Figura 6 – Matriz de Confusão do Experimento 1 . . . . .	28
Figura 7 – Gráfico das métricas geradas . . . . .	28
Figura 8 – Diagrama do modelo MLP . . . . .	29
Figura 9 – Resultado do Experimento 2 . . . . .	30
Figura 10 – Matriz de Confusão do Experimento 2 . . . . .	30
Figura 11 – Gráfico das métricas geradas . . . . .	31
Figura 12 – Resultado do Experimento 3 . . . . .	32
Figura 13 – Matriz de Confusão do Experimento 3 . . . . .	33
Figura 14 – Gráfico das métricas geradas . . . . .	34
Figura 15 – Resultado do Experimento 4 . . . . .	35
Figura 16 – Matriz de Confusão do Experimento 4 . . . . .	36
Figura 17 – Gráfico das métricas geradas . . . . .	36

# Lista de abreviaturas e siglas

**AI** - Artificial Intelligence.

**AP** - Agricultura de Precisão.

**CNN** - Convolutional Neural Network.

**FN** - Falso Negativo.

**FP** - Falso Positivo.

**ML** - Machine Learning.

**MLP** - Multilayer Perceptron.

**RGB** - Red, Green e Blue.

**VN** - Verdadeiro Negativo.

**VP** - Verdadeiro Positivo.

# Sumário

<b>1</b>	<b>INTRODUÇÃO</b>	<b>13</b>
<b>1.1</b>	<b>Problemática</b>	<b>13</b>
<b>1.2</b>	<b>Justificativa</b>	<b>14</b>
<b>2</b>	<b>OBJETIVOS</b>	<b>15</b>
<b>2.1</b>	<b>Objetivos Específicos</b>	<b>15</b>
<b>3</b>	<b>REVISÃO DA LITERATURA</b>	<b>16</b>
<b>3.1</b>	<b>Agricultura de precisão</b>	<b>16</b>
<b>3.2</b>	<b>Processamento de Imagens Para Reconhecimento de Padrões</b>	<b>16</b>
<b>3.3</b>	<b>Artificial Intelligence</b>	<b>17</b>
<b>3.4</b>	<b>Machine Learning</b>	<b>18</b>
<b>3.5</b>	<b>Deep Learning</b>	<b>18</b>
<b>3.5.1</b>	<b>Aprendizado Supervisionado</b>	<b>19</b>
<b>3.6</b>	<b>Multilayer Perceptron (MLP)</b>	<b>20</b>
<b>3.7</b>	<b>Convolutional Neural Network (CNN)</b>	<b>20</b>
<b>4</b>	<b>METODOLOGIA</b>	<b>22</b>
<b>4.1</b>	<b>Hipóteses e Descrição dos Experimentos</b>	<b>25</b>
<b>5</b>	<b>RESULTADOS</b>	<b>26</b>
<b>6</b>	<b>CONCLUSÃO</b>	<b>38</b>
	<b>REFERÊNCIAS</b>	<b>39</b>

# 1 Introdução

O trabalho está estruturado em capítulos que abordarão diferentes temas. O primeiro capítulo é a introdução, que compreende os subtópicos de justificativa, problema, objetivos gerais e específicos, metodologia e hipóteses. Em seguida, no segundo capítulo, será realizada uma revisão da literatura, onde serão abordados de forma concisa temas como Agricultura de Precisão, processamento de imagens para reconhecimento de padrões, Inteligência Artificial, Aprendizado de Máquina, Redes Neurais Convolucionais e Perceptron Multicamadas.

No terceiro capítulo, será descrita a metodologia utilizada no trabalho, contemplando a coleta e preparação dos dados, seleção e implementação dos modelos, além das métricas e procedimentos de validação adotados. Os resultados obtidos serão apresentados no quarto capítulo, com análises e interpretações dos dados coletados.

Por fim, o trabalho será concluído com um capítulo de conclusão, onde serão destacados os principais achados, contribuições e possíveis direções futuras de pesquisa. Em resumo, o trabalho abordará todos esses tópicos mencionados, proporcionando uma visão abrangente e conclusiva sobre o assunto estudado.

## 1.1 Problemática

O Brasil, como um importante produtor agrícola, enfrenta o desafio de otimizar suas práticas agrícolas. Uma área em que a otimização é essencial é o uso eficiente de defensivos agrícolas, e é aí que as tecnologias de detecção de plantas podem desempenhar um papel crucial. A inteligência artificial surge como uma ferramenta poderosa para auxiliar os engenheiros agrônomos na detecção de diversos tipos de plantas, oferecendo suporte na tomada de decisões desse profissional.

A agricultura de precisão, conforme mencionado por Duncan et al. (2021), é um setor em rápido desenvolvimento que combina as indústrias agrícola e tecnológica, sendo reconhecido como uma oportunidade "revolucionária" para enfrentar desafios como a segurança alimentar, questões ambientais e a criação de novos mercados. Nesse contexto, a aplicação da inteligência artificial e técnicas de classificação de imagens de mudas de plantas visa aprimorar um dos processos fundamentais da agricultura.

Através da inteligência artificial e da análise de imagens, é possível desenvolver sistemas capazes de identificar e classificar diferentes tipos de mudas de plantas com alta precisão e eficiência. Essa tecnologia pode ajudar os engenheiros agrônomos a identificar espécies de plantas indesejadas, diagnosticar doenças e pragas, além de avaliar a qualidade

das mudas. Com essas informações, é possível tomar decisões mais informadas e estratégicas para otimizar o uso de defensivos agrícolas, reduzir custos e minimizar os impactos ambientais.

Dessa forma, a combinação da agricultura de precisão com a inteligência artificial e a análise de imagens oferece uma abordagem inovadora e promissora para impulsionar a eficiência e a sustentabilidade na agricultura brasileira. Ao melhorar a detecção e classificação de plantas, os profissionais agrícolas podem tomar decisões mais assertivas e adotar medidas mais eficazes para garantir o sucesso dos cultivos, contribuindo para o avanço do setor agrícola no país.

## 1.2 Justificativa

O fim do nomadismo e o surgimento dos primeiros assentamentos humanos baseados na agricultura, houve a necessidade de classificar as plantas, conforme descrito por [Wells e Stock \(2020\)](#). A transição de alimentos obtidos através da caça e coleta para a agricultura levou à busca pelas melhores sementes, visando obter as melhores plantas e frutos. Nesse contexto, surge a agricultura de precisão.

A agricultura de precisão é uma abordagem que utiliza tecnologias avançadas para otimizar o cultivo de plantas, levando em consideração suas características individuais, necessidades específicas e as condições do ambiente. Essa prática busca maximizar a eficiência do uso de recursos, como água, fertilizantes e pesticidas, minimizando o desperdício e os impactos ambientais.

Através da agricultura de precisão, os agricultores podem realizar um manejo mais preciso e personalizado das plantas, monitorando sua saúde, aplicando tratamentos específicos quando necessário e identificando áreas que necessitam de intervenção. Isso contribui para a produção de alimentos de maior qualidade, aumento da produtividade e redução dos custos de produção.

Portanto, a agricultura de precisão surge como uma resposta à necessidade de obter melhores resultados na produção agrícola, proporcionando um uso mais eficiente dos recursos disponíveis e contribuindo para o desenvolvimento de um sistema agrícola sustentável.

## 2 Objetivos

Analisar modelos de aprendizado de máquina para a classificação de mudas de plantas com o proposito de encontrar o modelo de melhor custo benefício, quanto aos recursos computacionais e precisão.

### 2.1 Objetivos Específicos

Para alcançar o objetivo geral do presente trabalho buscar-se-á cumprir os seguintes objetivos específicos:

1. Identificar na literatura pelos menos dois modelos de aprendizado de máquina apropriados para o contexto de classificação de imagens de mudas de plantas;
2. Criar o ambiente de *Testbed*;
3. Avaliar os modelos de aprendizados selecionados utilizando pelo menos quatro métricas;
4. Discutir os resultados dos experimentos.



## 3 Revisão da literatura

Ao Longo dos anos, pesquisadores vem buscando criar um sistema para fazer a classificação de mudas de plantas, isto é, conseguir diferenciar os brotos das plantas desejadas das ervas daninhas, segundo [Giselsson et al. \(2017\)](#), no qual, as abordagens utilizadas vão desde mapas de ervas daninhas construídos usando dados grosseiros de sensoriamento remoto até pulverização de precisão em tempo real usando plataformas terrestres equipadas com sensores de imagens de alta resolução. Desta forma, mesmo sendo abordagens diferentes, a intenção de classificar mudas de plantas em uma plantação é a mesma. Em vista disso, surge a necessidade de utilização de um modelo inteligência artificial para detectar mudas de plantas tendo em vista o melhor custo benefício, quanto aos recursos computacionais e precisão. Deste modo, surge a necessidade de processar imagens para reconhecimento de padrões, como uma ferramenta para a agricultura de precisão.

### 3.1 Agricultura de precisão

A agricultura de precisão, de acordo com [Duncan et al. \(2021\)](#), é um setor em constante evolução que se situa na interseção entre as indústrias agrícola e tecnológica. É amplamente reconhecida como uma oportunidade “revolucionária” para atender às necessidades alimentares de uma população em crescimento, lidar com desafios ambientais e impulsionar o surgimento de novos mercados. Segundo [Sott et al. \(2021\)](#), na área da Agricultura de Precisão (AP), existem diversos termos e conceitos que abrangem diferentes setores e abordagens, como horticultura, pecuária e aquicultura. Esses setores desempenham um papel crucial na produção de alimentos, sendo considerados “capital concentrado” e gerenciáveis tanto do ponto de vista econômico quanto tecnológico.

A agricultura de precisão, quando combinada com precisão e tecnologia adequada, desempenha um papel fundamental na produção de alimentos de maneira eficiente, sustentável e econômica. Ela oferece oportunidades para maximizar o potencial produtivo desses setores, considerando suas particularidades e otimizando o uso de recursos como água, energia e insumos agrícolas. Nesse contexto, surge a necessidade do processamento de imagens para o reconhecimento de padrões.

### 3.2 Processamento de Imagens Para Reconhecimento de Padrões

O reconhecimento de padrões tem sido objeto de estudo há bastante tempo, como descrito por [Bianchi \(2006\)](#). Com o avanço e a disponibilidade de diversos recursos

computacionais, o projeto e a utilização de métodos sofisticados de análise e classificação tornaram-se mais acessíveis. Isso significa que agora é possível implementar técnicas complexas de reconhecimento de padrões, como redes neurais.

No campo do processamento de imagens para reconhecimento de padrões, como apontado por [Campos et al. \(2020\)](#), existem diversos sistemas baseados em métodos de classificação. Alguns desses métodos incluem redes neurais, sistemas imunológicos artificiais, lógica *fuzzy*, perceptron de multicamadas, entre outros. Essas abordagens têm sido amplamente exploradas e aplicadas para a classificação de imagens, visando identificar e reconhecer padrões relevantes em conjuntos de dados visuais. dessa maneira, no contexto deste trabalho será abordado apenas rede neural convolucional e perceptron de multicamadas, visto que, pertencem ao escopo da *Artificial Intelligence*.

### 3.3 Artificial Intelligence

A inteligência artificial ou no termo original em inglês *Artificial Intelligence* (AI) busca, conforme descrito por [Pandl et al. \(2020\)](#), permitir que os computadores executem tarefas fáceis para as pessoas, mas difíceis de descrever formalmente. Em suma, tais tarefas normalmente ocorrem em ambientes complexos ou incertos.

De acordo com ([SILVA; MAIRINK, 2019](#)), o termo AI já era objeto de discussão desde os anos 1950, quando Alan Turing abordou o assunto. No entanto, foi somente em 1956 que John McCarthy mencionou o termo em uma conferência nos Estados Unidos. Isso indica que o termo “inteligência artificial” é discutido há bastante tempo e tem sido objeto de pesquisa e desenvolvimento ao longo das décadas.

Conforme descrito por ([SILVA; MAIRINK, 2019](#)), a *Artificial Intelligence* (AI) pode ser aplicada em qualquer área do conhecimento. O objetivo é otimizar tarefas, visando reduzir o tempo gasto em sua execução. A IA oferece um conjunto diversificado de técnicas e abordagens, como aprendizado de máquina, redes neurais, algoritmos genéticos e lógica fuzzy, que podem ser adaptadas e aplicadas em diversos domínios. Ao automatizar tarefas complexas ou repetitivas, a IA permite que os sistemas ajam de forma autônoma e eficiente, contribuindo para aumentar a produtividade e a eficácia em várias áreas do conhecimento.

Em 2018 de acordo com [Bughin et al. \(2018\)](#) há uma estimativa que a aplicação da AI em vários setores pode gerar uma produção econômica global adicional de cerca de US\$ 13 trilhões até 2030. Nesse sentido, a utilização de AI vinculado a alguma técnica de *Machine Learning* torna-se indispensável.

### 3.4 Machine Learning

O termo *Machine Learning* (ML), em tradução literal Aprendizado de Máquina, é bastante abrangente, visto que, há diversos algoritmos e teoremas matemáticos, que segundo [Bonetto e Latzko \(2020\)](#) pode-se definir como estratégias de aprendizado de máquina, como, uma observação do estado de um sistema por meio de um modelo paramétrico que produz previsões com base no estado do sistema observado, em síntese, deverá encontrar os melhores parâmetros definidos para o modelo fornecido para maximizar a precisão da previsão em relação à tarefa em questão.

Conforme descrito por ([MONARD; BARANAUSKAS, 2003](#)), o *machine learning* é uma ferramenta poderosa para a aquisição automática de conhecimento. No entanto, é importante observar que não existe um único algoritmo que apresente o melhor desempenho para todos os problemas. Cada algoritmo possui suas próprias características e limitações, e é essencial compreender tanto o poder quanto as limitações dos diferentes algoritmos de aprendizado de máquina.

Uma abordagem recomendada é utilizar uma metodologia que permita avaliar os conceitos induzidos por esses algoritmos em problemas específicos. Isso envolve a seleção adequada dos algoritmos de aprendizado de máquina, a definição de métricas de desempenho relevantes e a realização de experimentos para comparar e analisar os resultados. Compreender as nuances dos algoritmos de aprendizado de máquina e suas aplicações específicas é fundamental para tomar decisões informadas e obter resultados satisfatórios na resolução de problemas.

ML é dividido de acordo com [Janiesch, Zschech e Heinrich \(2021\)](#) em três tipos: supervisionado, onde requer um conjunto de dados de treinamento que abrange entradas e saídas; não supervisionado, onde, o sistema detecta padrões sem rótulos ou rótulos pré-existentes e aprendizado por reforço em que em vez de fornecer uma entrada e saída, é especificado uma meta e uma lista de ações permitidas ou não, neste sentido, o modelo de ML alcançará o resultado pretendido sozinho, onde é utilizado o princípio da tentativa e erro para ter um melhor resultado. Portanto, uma das áreas do *machine learning* é a *deep learning*.

### 3.5 Deep Learning

O aprendizado profundo, também conhecido como *Deep Learning* em inglês, tem em vista emular o funcionamento da mente humana. Conforme descrito por [Bengio, Lecun e Hinton \(2021\)](#), esse paradigma é inspirado no cérebro e considera as representações aprendidas a partir de dados como a essência da inteligência. O objetivo é implementar a aprendizagem através da modificação das conexões, seja desenhando ou desenvolvendo

regras para tal. Essas conexões são utilizadas para detectar objetos em imagens, por exemplo.

Os algoritmos de aprendizado profundo segundo [Bezerra \(2016\)](#), pretendem produzir representações hierárquicas de alto nível das características dos dados. Eles podem aprender automaticamente as características mais relevantes dos dados de entrada, em vez de depender de regras explicitamente programadas. Isso permite que o aprendizado profundo seja aplicado em uma ampla gama de tarefas, como reconhecimento de padrões, processamento de linguagem natural e visão computacional.

A abordagem do aprendizado profundo tem obtido resultados significativos em diversas áreas, impulsionando avanços em tecnologia, como reconhecimento de fala, tradução automática e diagnóstico médico. Sua capacidade de aprender representações complexas e de alto nível dos dados tem contribuído para o desenvolvimento de sistemas mais inteligentes, de baixo custo e eficazes.

### 3.5.1 Aprendizado Supervisionado

De acordo com [Bezerra \(2016\)](#), no aprendizado de máquina, mais especificamente no aprendizado supervisionado, utiliza-se um conjunto de treinamento para ajustar os valores dos parâmetros da rede neural para minimizar o erro de treinamento ou *training error*. Nesse contexto, o treinamento de uma rede neural é transformado em um problema de otimização, cujo objetivo é reduzir o erro cometido pela rede ao considerar todos os exemplos de treinamento.

O processo de ajuste dos parâmetros da rede neural conforme pontuado por [Bezerra \(2016\)](#), é realizado iterativamente, utilizando técnicas de otimização, como o método do gradiente descendente. O objetivo é encontrar os valores ótimos para os parâmetros, de modo que o erro da rede em relação aos exemplos de treinamento seja minimizado. Essa abordagem permite que a rede neural aprenda a mapear corretamente as entradas para as saídas desejadas, conforme fornecidas no conjunto de treinamento.

Ao minimizar o erro de treinamento, espera-se que a rede neural consiga generalizar bem e produzir previsões ou classificações precisas para novos dados que não foram utilizados no treinamento. O aprendizado supervisionado, com o uso de técnicas de otimização, desempenha um papel fundamental no ajuste dos parâmetros da rede neural para obter um bom desempenho em tarefas de classificação, regressão ou qualquer outra tarefa específica. Portanto, o aprendizado supervisionado é uma abordagem bastante importante na *Convolutional Neural Network*, como também no *Multilayer Perceptron*.

### 3.6 Multilayer Perceptron (MLP)

Conforme descrito por [Wu \(2021\)](#), o *Multilayer Perceptron* (MLP) ou Perceptron Multicamadas é uma rede neural com uma única camada computacional. Essa rede consiste em uma camada de neurônios de entrada e uma camada de saída. Os pesos de todos os neurônios, exceto o último neurônio, são definidos antecipadamente, e o algoritmo de aprendizado perceptron é usado para aprender os pesos do último neurônio.

A principal característica do MLP é calcular o valor de adaptação com base na avaliação da interação do usuário. Os pesos dos neurônios da primeira camada são definidos artificialmente, e a qualidade do projeto desses neurônios afetará diretamente o desempenho do modelo perceptron multicamadas.

De acordo com [Ren et al. \(2022\)](#), o MLP é considerado uma rede computacional básica, em comparação com redes de aprendizado profundo, e tem um baixo custo computacional. No entanto, para que o MLP seja de baixo custo, pode ser necessário realizar algum tipo de tratamento nos dados, como a compressão. Apesar disso, o MLP ainda pode fornecer resultados interessantes para a classificação de imagens de mudas de plantas.

Em resumo, o MLP ou Perceptron Multicamadas é uma rede neural com uma única camada computacional, onde os pesos dos neurônios são definidos antecipadamente. Embora seja considerada uma rede de baixo custo computacional em comparação com redes de aprendizado profundo, pode ser eficaz na classificação de imagens de mudas de plantas, caso seja realizado o devido tratamento dos dados. Dessa forma, uma variação desta rede é a *Convolutional Neural Network*.

### 3.7 Convolutional Neural Network (CNN)

*Convolutional Neural Network* ou Rede Neural Convolutional, baseia-se na utilização de filtros para classificação do objeto conforme descrito por [Bensaadi e Louchene \(2023\)](#) na arquitetura CNN, o vetor de pesos e viés é chamado de filtro, cada filtro representa uma característica particular da entrada, desta maneira, o algoritmo calcula camada por camada para poder apreender o objeto.

De acordo com [Vargas, Paes e Vasconcelos \(2016\)](#), uma *Convolutional Neural Network* (CNN) é uma variação das redes de *Multilayer Perceptron* que foi inspirada no processamento biológico de dados visuais. Essa arquitetura foi desenvolvida visando lidar com tarefas de visão computacional de maneira semelhante aos processos tradicionais de análise visual.

A principal característica das CNNs conforme descrito por [Vargas, Paes e Vasconcelos \(2016\)](#), é a utilização de camadas convolucionais, que podem extrair características relevantes das imagens de entrada mediante operações de convolução. Essas camadas são

projetadas para detectar padrões visuais localmente, como bordas, texturas ou regiões específicas da imagem.

Além das camadas convolucionais, as CNNs também podem incluir camadas de *pooling*, responsáveis por reduzir a dimensionalidade das características extraídas. Isso ajuda a simplificar o processamento e torna a rede mais robusta a variações de escala e posição dos objetos nas imagens.

Uma vez que as características relevantes são extraídas, as CNNs podem utilizar camadas totalmente conectadas, semelhantes às redes de Perceptron multicamadas tradicionais, para realizar a classificação ou a regressão dos dados.

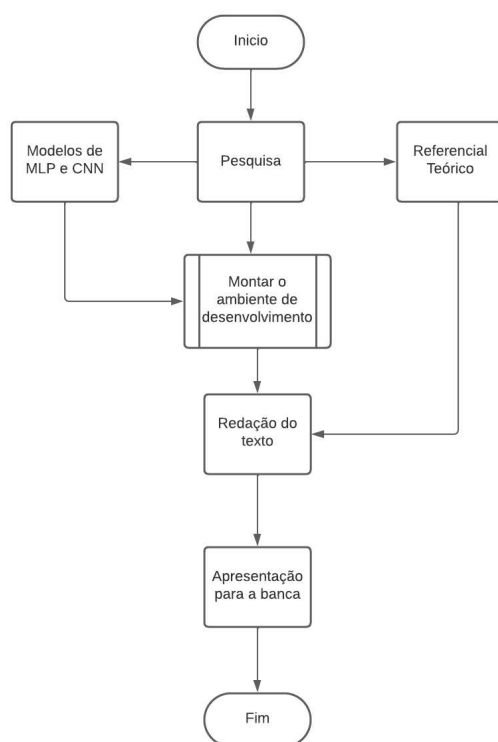
Em resumo, as CNNs são uma variação das redes de *Multilayer Perceptron*, projetadas especificamente para tarefas de visão computacional. Elas podem aprender automaticamente as características relevantes das imagens e têm se mostrado altamente eficazes em diversas aplicações, como reconhecimento de objetos, segmentação de imagens e detecção de padrões visuais.

## 4 Metodologia

O presente trabalho usa estudo de caso exploratório, a fim de verificar se há ou não um grande salto de qualidade no processamento de imagens mediante *Deep Learning* em relação às Redes Neurais Clássicas. Isto é, utilizar Redes Neurais com finalidade de comparar seu desempenho para evidenciar a rede mais adequada para a classificação de imagens de mudas de plantas.

O desenvolvimento deste trabalho seguiu um fluxo sequencial de processos para chegar aos resultados desejados. Inicialmente, foi realizado o processo de pesquisa, que foi dividido em dois sub-processos: a pesquisa do referencial teórico e a pesquisa dos modelos de perceptron multicamadas e rede neural convolucional. Em seguida, o próximo processo foi a montagem do ambiente de desenvolvimento, onde foram configuradas as ferramentas e tecnologias necessárias. Após isso, foi realizada a redação do texto, onde os resultados da pesquisa e implementação foram documentados. Por fim, o trabalho foi concluído com a apresentação dos resultados em uma apresentação ou exposição. Conforme demonstrado na Figura 1.

Figura 1 – Fluxograma do Trabalho



Fonte: Autor, 2023

No processo de obtenção dos resultados, foram utilizadas várias ferramentas, in-

cluindo o *Jupyter Notebook*, *Python*, *VSCode*, *Docker*, *TensorFlow* e *Keras*. Para a implementação dos modelos de redes neurais, foram empregadas as camadas de ativação *ReLU* (*Rectified Linear Unit*) e *Softmax*. Durante a compilação do modelo, optou-se pelo otimizador *Adam*, a função de perda *Sparse Categorical Crossentropy* e a métrica *Accuracy*.

As métricas utilizadas baseiam-se nas formas consolidadas na literatura para medir o desempenho dos processos de detecção de objetos em imagens. Portanto, este trabalho utiliza a matriz de confusão, para determinar as taxas de sucesso.

A **matriz de confusão** conforme descrito por (SKEIKA et al., 2019) usa o conceito de verdadeiro/positivo e falso/negativo para fazer a comparação dos *pixels* das imagens de forma segmentada. Além disso, é possível determinar a imagem *ground truth* (imagem de referência) e a taxa de acertos e erros. Como resultado, podem ocorrer quatro situações, são elas:

- **Verdadeiro Positivo (VP)** : é a representação do total de *pixels* segmentados, assim, quanto maior for a taxa melhor o resultado;
- **Verdadeiro Negativo (VN)**: é um *pixel* identificado corretamente como não pertencente a imagem alvo;
- **Falso Positivo (FP)**: é um *pixel* que não pertence ao alvo, entretanto, foi classificado como pertencente;
- **Falso Negativo (FN)**: Mede a taxa de *pixels* pertencentes a imagem alvo, todavia, foram classificados como não pertencentes.

A partir da matriz de confusão segundo (SKEIKA et al., 2019), os resultados obtidos são utilizados para gerar as taxas de sucesso, sendo elas *accuracy*, *f1-score*, *precision* e *recall*.

A ***accuracy*** (acurácia) são todos os acertos. Portanto, é definido pela soma dos verdadeiros negativos com verdadeiros positivos divididos pelo somatório de todas as situações.

$$Accuracy = \frac{|FP| + |FN|}{|FP| + |FN| + |VN| + |VP|} \quad (4.1)$$

(SKEIKA et al., 2019)

A ***precision*** (precisão) mede todos os *pixels* positivos verdadeiros na imagem de referência dividido pela soma dos verdadeiros positivos com os falsos positivos.

$$Precision = \frac{|VP|}{|VP| + |FP|} \quad (4.2)$$



(SKEIKA et al., 2019)

O **recall** (sensibilidade) mede total de todos os positivos encontrados. isto é, o verdadeiro positivo é dividido pela soma do verdadeiro positivo com o falso negativo.

$$recall = \frac{|VP|}{|VP| + |FN|} \quad (4.3)$$

(SKEIKA et al., 2019)


O **f1-score** é uma medida da precisão de teste baseado na média harmônica da *precision* e *recall*.

$$F1 - score = \frac{2 \times precision \times recall}{precision + recall} \quad (4.4)$$

(IWENDI et al., 2020)

A comparação das Redes Neurais dar-se-á com *dataset* comum, sendo a base de dados disponibilizada pela Universidade de Aarhus em uma colaboração com a Universidade do Sul da Dinamarca, conhecida por *Plant Seedlings Dataset* <sup>1</sup>. Este conjunto de dados é composto por imagens de mudas de plantas, com cerca de 960 plantas únicas, pertencentes a 12 espécies em vários estágios de crescimento conforme a Figura 2. Além disso, as figuras utilizam o sistema de cores aditivas RGB (vermelho, verde e azul) anotadas com uma resolução física por volta de 10 *pixels* por mm. Apesar de utilizar um dataset não próprio, o tratamento e análise dos dados gerados pelo estudo de caso sucederá quantitativa e qualitativamente.

Figura 2 – Mosaico com exemplos de imagens de mudas plantas



Fonte: Autor, 2023

A Figura 2 apresenta exemplos de 12 classes de mudas de plantas que estão incluídas no dataset.

<sup>1</sup> <<https://vision.eng.au.dk/plant-seedlings-dataset/>>

## 4.1 Hipóteses e Descrição dos Experimentos

O uso da inteligência artificial para classificar objetos tem se expandido para diversas áreas, inclusive a botânica. Nesse contexto, algumas hipóteses podem ser formuladas sobre os benefícios e desafios dessa aplicação, são elas:

- H0: Não há um grande salto de qualidade no processamento de imagens através da rede *Convolutional Neural Network* em relação a rede *Multilayer Perceptron*;
- H1: Há um grande salto de qualidade no processamento de imagens através da rede *Convolutional Neural Network* em relação a rede *Multilayer Perceptron*.

Faz-se necessário a realização de testes para verificar as hipóteses apresentadas. Neste sentido, propõe-se a realização de três experimentos considerando as métricas de avaliação de performance do sistema. Dado isto, os seguintes cenários são considerados:

- E1: (experimento um): Escolher duas espécies de mudas de plantas dentre todas contidas na base de dados, além disso, todas as imagens de mudas de plantas estão separados em pastas, dessa forma, utilizando um algoritmo de *Convolutional Neural Network* com a configuração de 80% para treino e 20% para teste, assim, buscando a maior precisão possível;
- E2: (experimento dois): Escolher duas espécies de mudas de plantas dentre todas contidas na base de dados, além disso, todas as imagens de mudas de plantas estão separados em pastas, dessa forma, utilizando um algoritmo de *Multilayer Perceptron* com a configuração de 80% para treino e 20% para teste, assim, buscando a maior precisão possível;
- E3: (experimento três): Para todas as espécies de mudas de plantas dentre todas contidas na base de dados, além disso, todas as imagens de mudas de plantas estão separados em pastas, dessa forma, utilizando um algoritmo de *Convolutional Neural Network* com a configuração de 80% para treino e 20% para teste, assim, buscando a maior precisão possível;
- E4: (experimento quatro): Para todas as espécies de mudas de plantas dentre todas contidas na base de dados, além disso, todas as imagens de mudas de plantas estão separados em pastas, dessa forma, utilizando um algoritmo de *Multilayer Perceptron* com a configuração de 80% para treino e 20% para teste, assim, buscando a maior precisão possível.

## 5 Resultados

No Experimento um (E1), conforme descrito na metodologia, foram utilizadas duas classes: *Maize* e *Small-flowered Cranesbill*. Essas classes foram divididas em 80% para treinamento e 20% para validação. Isso resultou em um total de 667 imagens destinadas ao treinamento e 166 imagens destinadas à validação, das 833 imagens disponíveis. Além disso, como parte do pré-processamento, as imagens foram normalizadas, ou seja, os valores dos vetores das imagens foram transformados para uma escala entre zero e um. Ademais, as imagens foram redimensionadas para o tamanho de 32 por 32 pixels, visando otimizar o tempo de processamento, como observado na Figura 3.

Figura 3 – Imagem Redimensionada.




Fonte: Autor, 2023

O modelo sequencial desenvolvido, ilustrado pela Figura 4, utiliza um total de 11 camadas. A primeira camada é a camada de entrada, sendo uma camada convolucional com um tamanho de *kernel* de 32. Essa camada usa a ativação *ReLU*, com um *input shape* de 32 por 32, correspondendo à largura e altura das imagens. Em seguida, temos uma camada *MaxPooling2D*. As duas camadas seguintes são camadas escondidas configuradas da seguinte maneira: uma camada com um *kernel* de 64 e a ativação *ReLU*, seguida por uma camada *MaxPooling*. Após isso, é utilizada uma camada *Flatten* para transformar a saída das camadas anteriores em um vetor unidimensional. Essa camada prepara os dados para a camada de saída. A camada de saída consiste em uma camada *Dense* (densa) com um *kernel* de 64 e a ativação *ReLU*. Por fim, temos outra camada *Dense* com um *kernel* adequado ao número de classes e a ativação *Softmax*. Essa última camada gera as probabilidades para cada classe, por conseguinte, obtendo 72.898 parâmetros.


Durante o treinamento do modelo, foi configurado para executar 100 épocas, visando obter o melhor resultado possível. Após o treinamento, foram alcançados 92,17% de acurácia e uma perda (loss) de 0,34. Esses resultados indicam que o modelo teve um desempenho promissor na tarefa de classificação, como observado na Figura 5.

Figura 4 – Diagrama do modelo CNN



Fonte: Autor, 2023

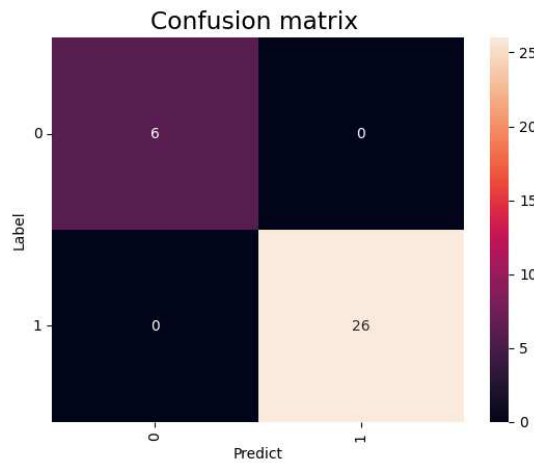
Figura 5 – Resultado do Experimento 1



Fonte: Autor, 2023

Com base nos resultados obtidos durante o treinamento, foi gerada uma matriz de confusão para avaliar o desempenho do modelo. Como observado na Figura 6. A matriz de confusão foi gerada da seguinte forma: o valor de Verdadeiro Positivo (VP) é seis, indicando que o modelo conseguiu corretamente prever a classe que estávamos buscando. Por outro lado, tanto o valor de Falso Positivo (FP) quanto o valor de Falso Negativo (FN) são zero. O valor de Verdadeiro Negativo (VN) é 26, o que significa que o modelo identificou corretamente que essas 26 predições não correspondem à classe *Maize*. Com base nesses resultados, foram geradas as métricas conforme a Figura 7.


Figura 6 – Matriz de Confusão do Experimento 1



Fonte: Autor, 2023

Figura 7 – Gráfico das métricas geradas

## Métricas E1



Fonte: Autor, 2023


Nesse caso, observa-se que todas as amostras rotuladas foram previstas corretamente. Para realizar a previsão, um lote de 32 imagens foi selecionado a partir do conjunto de dados de validação, com o propósito de testar o modelo. Dessas amostras, seis foram classificadas como "Maize" e 26 como "Small-flowered Cranesbill". Isso indica que nesse caso o modelo conseguiu prever todas as imagens.

No experimento dois (E2) conforme descrito na metodologia, foram utilizadas duas

classes: *Maize* e *Small-lowered Cranesbill*. Essas classes foram divididas em 80% para treinamento e 20% para validação. Isso resultou em um total de 667 imagens destinadas ao treinamento e 166 imagens destinadas à validação, das 833 imagens disponíveis. Como pré-processamento apenas foi feito o redimensionamento das imagens, conforme já mostrado na Figura 3.

O modelo MLP desenvolvido para este experimento, ilustrado pela Figura 8 utiliza uma camada *Flatten* como camada de entrada. Essa camada recebe as imagens já redimensionadas para o tamanho de 32 por 32 *pixels*. Nas camadas ocultas, são empregadas três camadas *Dense* com diferentes tamanhos de kernel: 32, 64 e 128. A função de ativação utilizada nessas camadas é a *ReLU*. Na camada de saída, é utilizada uma camada *Dense* com um *kernel* que corresponde ao número de classes do problema, e o ativador utilizado é o *Softmax*. Isso resulta em um total de 110.316 parâmetros.

Figura 8 – Diagrama do modelo MLP

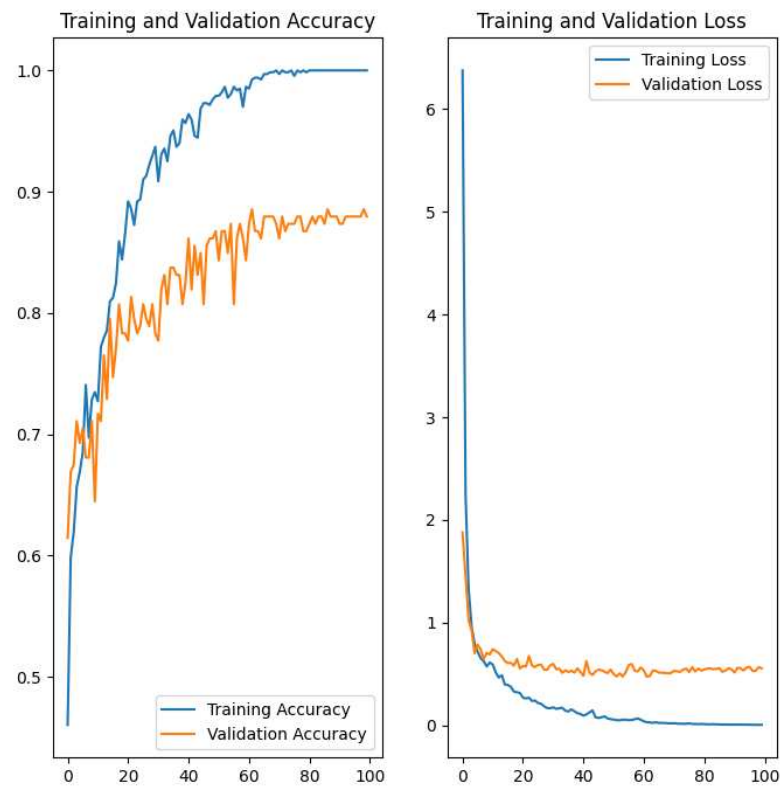


Fonte: Autor, 2023

Para a compilação do modelo, também foi utilizado o otimizador Adam com um parâmetro de taxa de aprendizado definido em 0,0001. Esse parâmetro é utilizado para ajustar a taxa de aprendizado durante o treinamento. A função de perda (loss) definida foi a sparse categorical crossentropy e a métrica escolhida foi a accuracy (acurácia). Durante o treinamento do modelo, foram executadas 100 epochs, para obter os melhores resultados possíveis. Após o treinamento, o modelo alcançou uma acurácia de 87,95% e uma perda (loss) de 0,55, conforme demonstrado na Figura 9.

Com base nos resultados obtidos durante o treinamento, foi gerada uma matriz de confusão para avaliar o desempenho do modelo. A matriz de confusão foi gerada da seguinte forma: o valor de Verdadeiro Positivo (VP) é seis, indicando que o modelo conseguiu corretamente prever a classe que estávamos buscando. Por outro lado, o valor de Falso Positivo (FP) é zero, e o Falso Negativo (FN) é três. O valor de Verdadeiro Negativo (VN) é 23, o que significa que o modelo identificou corretamente que essas 23 predições não correspondem à classe *Maize*, mas também ocorreram três predições erradas. Como


Figura 9 – Resultado do Experimento 2



Fonte: Autor, 2023

observado na Figura 10.


Figura 10 – Matriz de Confusão do Experimento 2



Fonte: Autor, 2023

Nesse caso, verifica-se que nem todos os valores rotulados foram previstos corretamente. Portanto, das 32 imagens utilizadas para testar o modelo, seis foram classificadas corretamente como *Maize* e 23 como *Small-flowered Cranesbill* e três foram classificadas erradas. Isso indica que a predição dentre as imagens de *maize* conseguiu acertar 67%, dessa forma gerando um *recall* de 100% e o F1-score de 80%, já entre as imagens de *Small-flowered Cranesbill* ocorreu uma taxa de 100% de acerto, *recall* de 88% e *f1-score* de 94%. conforme a Figura 11.

Figura 11 – Gráfico das métricas geradas



Fonte: Autor, 2023

No Experimento três (E3), conforme descrito na metodologia, foram utilizadas todas as 12 classes contidas no dataset. Essas classes são: Black Grass, Charlock, Cleavers, Common Chickweed, Common Wheat, Fat Hen, Loose Silky-bent, Maize, Scentless Mayweed, Shepherd's Purse, Small-flowered Cranesbill e Sugar Beet. A divisão dos dados foi feita em 80% para treinamento e 20% para validação. Isso resultou em um total de 4.432 imagens destinadas ao treinamento e 1.107 imagens destinadas à validação, das 5.539 imagens disponíveis.

Como parte do pré-processamento, as imagens foram normalizadas, ou seja, os valores dos vetores das imagens foram transformados para uma escala entre zero e um. Além disso, as imagens foram redimensionadas para o tamanho de 32 por 32 pixels, a fim de otimizar o tempo de processamento.


O modelo CNN desenvolvido utiliza um total de cinco camadas. Como ilustrado



na Figura 4. A primeira camada é a camada de entrada, sendo uma camada convolucional com um tamanho de *kernel* de 32. Essa camada usa a ativação *ReLU*, com um *input shape* de 32 por 32, correspondendo à largura e altura das imagens. Em seguida, temos uma camada *MaxPooling2D*. As duas camadas seguintes são camadas escondidas configuradas da seguinte maneira: uma camada com um *kernel* de 64 e a ativação *ReLU*, seguida por uma camada *MaxPooling*. Após isso, é utilizada uma camada *Flatten* para transformar a saída das camadas anteriores em um vetor unidimensional. Essa camada prepara os dados para a camada de saída. A camada de saída consiste em uma camada *Dense* (densa) com um *kernel* de 64 e a ativação *ReLU*. Por fim, temos outra camada *Dense* com um *kernel* adequado ao número de classes e a ativação *Softmax*. Essa última camada gera as probabilidades para cada classe, por conseguinte, obtendo 73.548 parâmetros.

Durante o treinamento do modelo, foi configurado para executar 100 épocas, visando obter o melhor resultado possível. Após o treinamento, foram alcançados 78,41% de acurácia e uma perda (loss) de 2,16. Esses resultados indicam que o modelo teve um desempenho promissor na tarefa de classificação, com observado na Figura 12.


Figura 12 – Resultado do Experimento 3



Fonte: Autor, 2023

Com base nos resultados obtidos durante o treinamento, foi gerada uma matriz de confusão para avaliar o desempenho do modelo. Como observado na Figura 13.

Figura 13 – Matriz de Confusão do Experimento 3



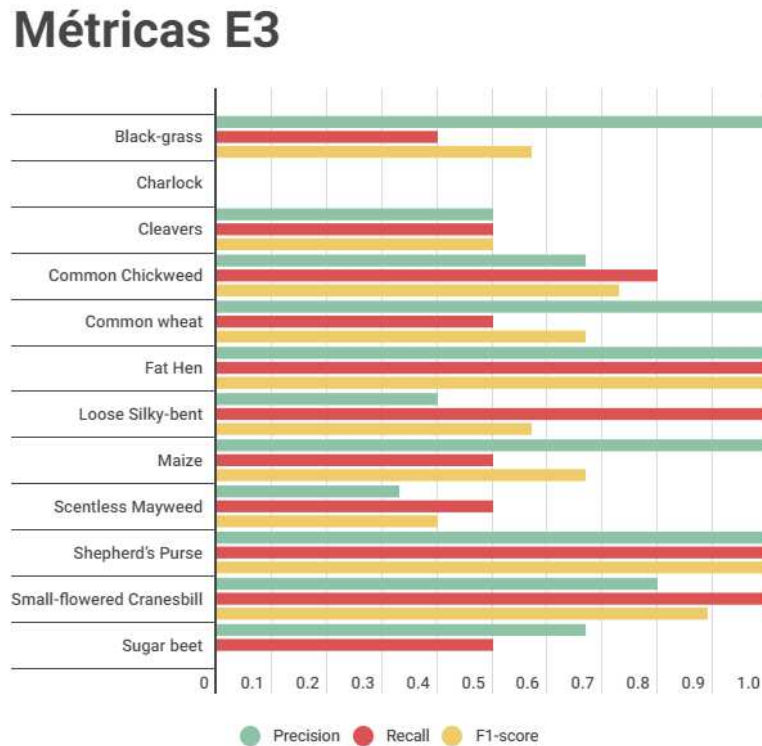
Fonte: Autor, 2023

A matriz de confusão foi gerada, com algumas observações relevantes:

- Na primeira classe, das cinco imagens previstas, o modelo acertou duas;
- Na segunda classe, não houve predições devido à falta de imagens correspondentes;
- Na terceira classe, apenas uma imagens foi corretamente prevista;
- Na quarta classe, das cinco imagens escolhidas, apenas um teve uma predição errada;
- Na quinta classe, das duas imagens, o modelo acertou uma;
- Na sexta classe, o modelo conseguiu prever corretamente a única imagem escolhida;
- Na sétima classe, o modelo acertou as duas imagens escolhidas;
- Nas oitava e nona classes, das duas imagens escolhidas em cada uma, o modelo acertou apenas uma em ambas;
- Na décima classe, das três imagens escolhidas, o modelo acertou todas;
- Na décima primeira classe, o modelo acertou todas as quatro imagens escolhidas;
- Na décima segunda classe, das quatro imagens escolhidas, o modelo acertou duas.

Essas observações foram utilizadas para gerar as métricas conforme a Figura 14.

Figura 14 – Gráfico das métricas geradas



Fonte: Autor, 2023

Nesse caso, verifica-se que algumas classes obtêm melhores resultados que outras. Por exemplo, a classe *Shepherd's Purse* conseguiu gerar *precision*, *recall* e *f1-score* de 100%. No entanto, a classe *Charlock*, das 32 imagens escolhidas aleatoriamente, não obteve nenhuma predição correta. A classe *Scentless Mayweed* apresentou os piores resultados, com uma *precision* de predição de 33%, *recall* de 50% e *f1-score* de 40%. Assim, esse experimento apresentou resultados positivos, embora com variações de desempenho entre as diferentes classes.


No Experimento quatro (E4), conforme descrito na metodologia, foram utilizadas todas as 12 classes contidas no dataset. Essas classes são: Black Grass, Charlock, Cleavers, Common Chickweed, Common Wheat, Fat Hen, Loose Silky-bent, Maize, Scentless Mayweed, Shepherd's Purse, Small-flowered Cranesbill e Sugar Beet. A divisão dos dados foi feita em 80% para treinamento e 20% para validação. Isso resultou em um total de 4.432 imagens destinadas ao treinamento e 1.107 imagens destinadas à validação, das 5.539 imagens disponíveis.

O modelo sequencial desenvolvido para este experimento utiliza uma camada *Flatten* como camada de entrada. Essa camada recebe as imagens já redimensionadas para o tamanho de 32 por 32 pixels. Nas camadas ocultas, são empregadas três camadas *Dense* com diferentes tamanhos de kernel: 32, 64 e 128. A função de ativação utilizada nessas

camadas é a *ReLU*. Na camada de saída, é utilizada uma camada *Dense* com um *kernel* que corresponde ao número de classes do problema, e o ativador utilizado é o *Softmax*. Isso resulta em um total de 110.316 parâmetros.

Para a compilação do modelo, também foi utilizado o otimizador Adam com um parâmetro de taxa de aprendizado definido em 0,0001. Esse parâmetro é utilizado para ajustar a taxa de aprendizado durante o treinamento. A função de perda (loss) definida foi a sparse categorical crossentropy e a métrica escolhida foi a accuracy (acurácia). Durante o treinamento do modelo, foram executadas 100 epochs, para obter os melhores resultados possíveis. Após o treinamento, o modelo alcançou uma acurácia de 27,82% e uma perda (loss) de 1,94, conforme demonstrado na Figura 15.


Figura 15 – Resultado do Experimento 4



Fonte: Autor, 2023

Com base nos resultados obtidos durante o treinamento, foi gerada uma matriz de confusão para avaliar o desempenho do modelo. Nesse caso, como o modelo não obteve uma boa acurácia apenas a quarta, sexta, sétima e décima segunda conseguiu fazer a predição correta de todas as imagens. Como observado na Figura 16. Essas observações foram utilizadas para gerar as métricas conforme a Figura 17.

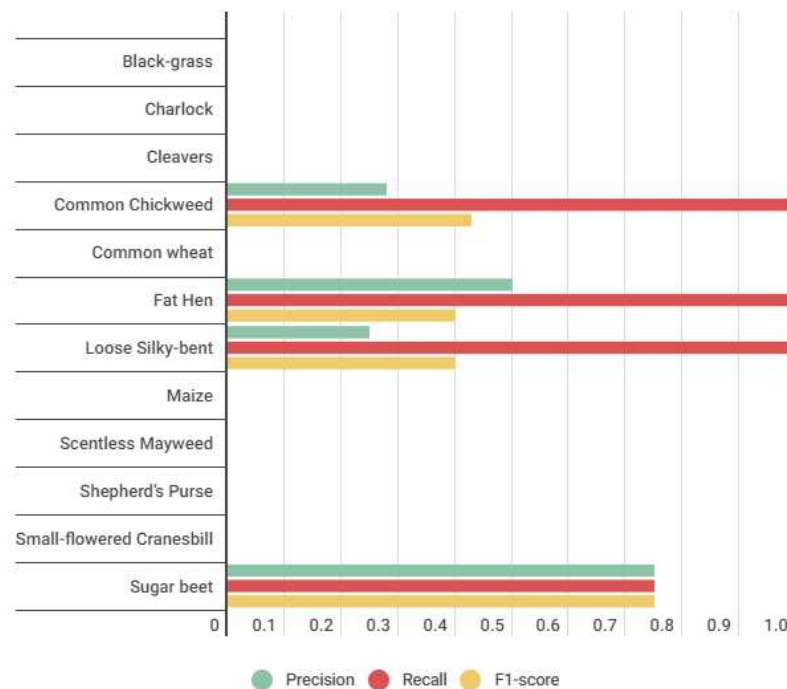
Figura 16 – Matriz de Confusão do Experimento 4



Fonte: Autor, 2023

Figura 17 – Gráfico das métricas geradas

## Métricas E4



Fonte: Autor, 2023

Nesse experimento, a classe que obteve o melhor resultado foi a *Sugar beet* com uma precisão (precision), *recall* e *f1-score* de 75%. No entanto, as classes *Common Chickweed* e *Loose Silky-bent* apresentaram um valor de revocação de 100%, o que significa que todos os exemplos relevantes dessas classes foram corretamente identificados. No entanto, a *precision* e a *f1-score* dessas classes foram baixas, o que indica que houve inúmeros falsos

positivos. Portanto, os resultados desse experimento, utilizando o modelo proposto, não são considerados satisfatórios.

## 6 Conclusão

O presente estudo teve como objetivo realizar um caso de uso exploratório utilizando uma base de dados disponibilizada pela Universidade de Aarhus, a fim de comparar o desempenho do processamento de imagens utilizando uma técnica de *Deep Learning* e uma rede neural clássica. Os resultados obtidos foram capazes de alcançar todos os objetivos propostos.

Ao analisar os experimentos realizados, constatou-se que ambas as técnicas de classificação foram capazes de classificar as imagens. No entanto, a técnica de classificação MLP obteve resultados consideráveis apenas para duas classes. Por outro lado, verificou-se que a técnica de *Deep Learning* CNN obteve resultados satisfatórios em ambos os experimentos.

Esses resultados evidenciam a eficácia da abordagem de *Deep Learning* na classificação de imagens, demonstrando um potencial significativo para o processamento de imagens em diversas aplicações. A contínua melhoria e refinamento dos modelos utilizados são fundamentais para impulsionar o avanço dessa área e explorar ainda mais seu potencial na solução de problemas complexos relacionados à identificação e classificação de imagens.

Para trabalhos futuros, pretende-se aprimorar o modelo MLP visando melhorar sua capacidade de classificar a base de dados utilizada neste estudo, buscando atingir uma acurácia mais alta e ser capaz de prever todas as classes com precisão.

# Referências

- BENGIO, Y. et al. Deep learning for ai. *Commun. ACM*, Association for Computing Machinery, New York, NY, USA, v. 64, n. 7, p. 58–65, jun 2021. ISSN 0001-0782. Disponível em: <<https://doi.org/10.1145/3448250>>.
- BENSAADI, S.; LOUCHENE, A. Low-cost convolutional neural network for tomato plant diseases classification. *IAES International Journal of Artificial Intelligence (IJ-AI)*, v. 12, n. 1, p. 162, mar. 2023. ISSN 2252-8938, 2089-4872. Disponível em: <<https://ijai.iaescore.com/index.php/IJAI/article/view/22192>>.
- BEZERRA, E. Introdução à aprendizagem profunda. *Artigo-31º Simpósio Brasileiro de Banco de Dados-SBBD2016-Salvador*, 2016.
- BIANCHI, M. F. d. *Extração de Características de imagens de faces humanas através de wavelets, PCA E IMPCA*. Biblioteca Digital de Teses e Dissertações da Universidade de São Paulo, 2006. Disponível em: <<https://www.teses.usp.br/teses/disponiveis/18/18133/tde-10072006-002119/pt-br.php>>.
- BONETTO, R.; LATZKO, V. Machine learning. In: *Computing in Communication Networks*. Elsevier, 2020. p. 135–167. ISBN 9780128204887. Disponível em: <<https://linkinghub.elsevier.com/retrieve/pii/B9780128204887000219>>.
- BUGHIN, J. et al. Notes from the ai frontier: Modeling the impact of ai on the world economy. *McKinsey Global Institute*, 2018.
- CAMPOS, M. B. P. d. et al. Inteligência artificial com aprendizado continuado aplicada ao reconhecimento de padrões / artificial intelligence with continuous learning applied to pattern recognition. *Brazilian Journal of Development*, v. 6, n. 5, p. 22778–22797, May 2020. Disponível em: <<https://ojs.brazilianjournals.com.br/ojs/index.php/BRJD/article/view/9440>>.
- DUNCAN, E. et al. New but for whom? Discourses of innovation in precision agriculture. *Agriculture and Human Values*, v. 38, n. 4, p. 1181–1199, dez. 2021. ISSN 0889-048X, 1572-8366. Disponível em: <<https://link.springer.com/10.1007/s10460-021-10244-8>>.
- GISELSSON, T. M. et al. *A Public Image Database for Benchmark of Plant Seedling Classification Algorithms*. 2017.
- IWENDI, C. et al. The use of ensemble models for multiple class and binary class classification for improving intrusion detection systems. *Sensors*, v. 20, n. 9, p. 2559, 2020. <https://www.mdpi.com/1424-8220/20/9/2559/pdf?version=1588335264>. Disponível em: <<https://app.dimensions.ai/details/publication/pub.1127370843>>.
- JANIESCH, C. et al. Machine learning and deep learning. *Electronic Markets*, v. 31, n. 3, p. 685–695, set. 2021. ISSN 1019-6781, 1422-8890. Disponível em: <<https://link.springer.com/10.1007/s12525-021-00475-2>>.
- MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. *Sistemas inteligentes-Fundamentos e aplicações*, v. 1, n. 1, p. 32, 2003.



PANDL, K. D. et al. On the Convergence of Artificial Intelligence and Distributed Ledger Technology: A Scoping Review and Future Research Agenda. *IEEE Access*, v. 8, p. 57075–57095, 2020. ISSN 2169-3536. Disponível em: <<https://ieeexplore.ieee.org/document/9039606/>>.

REN, R. et al. Novel low-power construction of chaotic s-box in multilayer perceptron. *Entropy*, v. 24, n. 11, p. 1552, 2022. <https://www.mdpi.com/1099-4300/24/11/1552/pdf?version=1668156354>. Disponível em: <<https://app.dimensions.ai/details/publication/pub.1152350170>>.

SILVA, J. A. S. da; MAIRINK, C. H. P. Inteligência artificial. *LIBERTAS: Revista de Ciências Sociais Aplicadas*, v. 9, n. 2, p. 64–85, 2019.

SKEIKA, E. L. et al. *Utilização de redes neurais completamente convolucionais para identificação e medição de crânios fetais*. Dissertação (Mestrado) — Universidade Tecnológica Federal do Paraná, 2019. Disponível em: <<https://repositorio.utfpr.edu.br/jspui/handle/1/4714>>.

SOTT, M. K. et al. A bibliometric network analysis of recent publications on digital agriculture to depict strategic themes and evolution structure. *Sensors*, v. 21, n. 23, p. 7889, 2021. <https://www.mdpi.com/1424-8220/21/23/7889/pdf?version=1637941952>. Disponível em: <<https://app.dimensions.ai/details/publication/pub.1143560010>>.

VARGAS, A. C. G. et al. Um estudo sobre redes neurais convolucionais e sua aplicação em detecção de pedestres. In: SN. *Proceedings of the xxix conference on graphics, patterns and images*. [S.l.], 2016. v. 1, n. 4.

WELLS, J. C. K.; STOCK, J. T. Life history transitions at the origins of agriculture: A model for understanding how niche construction impacts human growth, demography and health. *Frontiers in Endocrinology*, v. 11, 2020. ISSN 1664-2392. Disponível em: <<https://www.frontiersin.org/articles/10.3389/fendo.2020.00325>>.

WU, J. A product styling design evaluation method based on multilayer perceptron genetic algorithm neural network algorithm. *Computational Intelligence and Neuroscience*, v. 2021, p. 2861292, 2021. <https://downloads.hindawi.com/journals/cin/2021/2861292.pdf>. Disponível em: <<https://app.dimensions.ai/details/publication/pub.1143591813>>.